

Processo ETL e Integração de Fontes

Avaliação 02 — Parte II · Modelagem de Data Warehouse (EEL890) · Tema:
locadora de veículos

Gustavo Oliveira Pessanha da Silva — DRE 122051824

André Vinícius Lobo Giron — DRE 122050404

Rio de Janeiro · 30 de maio de 2026

Sumário

1. Introdução
 2. Fontes e escolhas
 3. Visão geral do ETL
 4. Transformações principais
 5. Relatórios e matriz de Markov
 6. Problemas encontrados
 7. Conclusão
- Referências

1. Introdução

Este relatório resume o **processo ETL** que usamos no trabalho da disciplina para integrar cinco bancos OLTP de locadoras em um único Data Warehouse. A ideia foi manter o processo simples e rastreável, com uma área de *staging* comum e cargas idempotentes. O modelo dimensional está no relatório irmão [docs/relatorio-dimensio-nal.pdf](#).

2. Fontes e escolhas

As cinco fontes integradas e seus schemas no Postgres:

sk_fonte	Schema	Origem
1	src_andre_gustavo	Parte I do próprio grupo
2	src_mae016	MySQL (traduzido)
3	src_locadora_db	PostgreSQL
4	src_bd_dw_26_1	MySQL (traduzido)
5	src_bigdata	ANSI SQL

Também avaliamos outras fontes, mas **três foram excluídas** porque não tinham atributos essenciais para os relatórios (cidade do cliente, grupo do veículo ou pátio de devolução). Isso ficou claro quando começamos a comparar as tabelas.

3. Visão geral do ETL

Seguimos o fluxo clássico **fontes** → **staging** → **DW**. Cada fonte é extraída de forma isolada, depois tudo passa por uma transformação comum e, por fim, carregamos as dimensões e os fatos.




Figura 1. Visão geral do ETL em três camadas (fontes → staging → DW).

O pipeline ficou com sete etapas, mas a execução é simples: extract das cinco fontes, transform único e load em sequência.




Figura 2. Pipeline resumido do ETL com etapas sequenciais.

4. Transformações principais

O que mais deu trabalho foi padronizar os dados antes do load:

- **Pátios e empresas:** nomes diferentes para os mesmos pátios; criamos um de/para simples para padronizar.
- **Grupos de veículos:** categorias com nomes diferentes (ex.: “SUV” vs “UTILITÁRIO”); ajustamos para um conjunto único.
- **Datas e chaves:** padronizamos datas para `DATE / TIMESTAMP` e criamos chaves substitutas nas dimensões.
- **Idempotência:** os scripts limpam a fatia da fonte antes de inserir, para permitir reexecução.

5. Relatórios e matriz de Markov

Com o DW pronto, geramos os quatro relatórios pedidos no enunciado:

1. Controle de pátio (frota própria vs. associadas).
2. Controle de locações.
3. Controle de reservas por cidade de origem.
4. Grupos mais alugados cruzados com cidade.

Também construímos a **matriz de Markov** de movimentação entre pátios usando as locações concluídas.



Figura 3. Matriz de Markov 6×6 com percentuais de movimentação.

6. Problemas encontrados

Alguns pontos que apareceram durante o desenvolvimento:

- **Campos faltando** em fontes candidatas (ex.: cidade do cliente), que obrigaram a exclusão de alguns grupos.
- **Inconsistências de nomes** (pátios e grupos), resolvidas com tabelas de-para.
- **Diferenças de SGBD** (MySQL → Postgres), que exigiram ajustes simples de DDL.

Esses problemas foram os principais motivos para manter o ETL direto e sem muitas camadas extras.

7. Conclusão

O ETL final ficou simples, mas atende ao enunciado. Conseguimos integrar as cinco fontes escolhidas, gerar o DW estrela e produzir os relatórios pedidos. Ainda há espaço para melhorias (ex.: automatizar traduções e validar dados), mas para o escopo da disciplina o resultado foi satisfatório.

Referências

- Kimball & Ross, *The Data Warehouse Toolkit*, 3ª ed.
- Elmasri & Navathe, *Sistemas de Banco de Dados*, 7ª ed.